

癌症風險代謝物分析

一、動機

癌症與代謝體之間存在一定的關聯性，因為人體內的代謝體種類繁多，若要針對每一種代謝體逐一進行實驗驗證，不僅耗費大量時間，實驗成本也相當高昂，難以在真實世界中逐一測試。因此，透過本平台的分析方法，我們可以先針對大量代謝體進行初步篩選，找出與癌症分類較具相關性、極有可能具有影響力的候選代謝體，藉此大幅縮小後續實驗驗證的範圍，讓研究人員能夠更有效率地聚焦資源，針對高機率相關的代謝體進行後續深入研究與驗證。

工具網址：https://cosbi10.ee.ncku.edu.tw/DEM_screener/

二、資料簡介

- 本資料集總共有 7 種癌症資料集，包含大腸直腸癌、肺癌、胰臟癌、肝癌、口腔癌、胃癌以及乳癌，另外再加上健康對照組，總共分為 4 種期別（Stage A、Stage B、Stage C、Stage D）。
- 各癌症別的樣本數如下：CRC 共 219 例、Lung 共 201 例、Pancreatic 共 200 例、Liver 共 161 例、Oral 共 197 例、Gastric 共 4 例、Breast 共 185 例，健康對照組則為 162 例，全部資料集合計樣本數為 1,329 例。

	癌症名稱	Stage A	Stage B	Stage C	Stage D	總數
CRC	大腸癌	39	56	78	46	219
Lung	肺癌	50	52	49	50	201
Pancreatic	胰臟癌	50	51	50	49	200
Liver	肝癌	50	50	50	11	161
Oral	口腔癌	49	35	53	60	197
Breast	乳癌	50	50	50	35	185
Healthy	健康對照組	N = 162	—	—	—	162

三、使用方法

1. 癌症選擇

- 在 “Select a cancer” 中可以選擇癌症別。目前共有 7 種癌症提供資料。
 - CRC
 - Liver
 - Breast
 - Lung
 - Oral
 - Pancreatic

使用資料:(原始資料)

- CRC : 219 人 | Normal : 162 人
 * Stage A : 39 人 | * Stage B : 56 人
 * Stage C : 78 人 | * Stage D : 46 人

Select a cancer:

Colorectal cancer

Colorectal cancer
 Liver cancer
 Breast cancer
 Liver cancer
 Lung cancer

Feature Filter :

- 在 "Select two stages" 中，可選擇兩種不同情況的資料，包含各期別，以及癌症患者與健康者的資料。

Select two stages:

Condition 1
 CRC (n=219)

vs.

Condition 2
 Normal (n=162)

Swap

Feature Filter :

> <

Value (%) > <

2. Threshold 設定

總共會有兩種資料結果：機器學習與統計測試

3. 機器學習資料

"Feature Filter" 屬於機器學習的資料集，。在建立模型之前，我們會先將樣本標上 Label：將 Condition 1 的樣本標記為 $y = 1$ ，Condition 2 的樣本標記為 $y = 0$ 。

另外，本網站共有兩種 Threshold 可以設定：AUC & Importance。我們可以選擇一個 Threshold，作為評估各代謝體在資料中重要程度的依據。

需注意的是，Importance 僅適用於癌症對健康 (Cancer vs. Healthy) 這類別的資料，若為其他分組比較 (例如不同癌症分期之間)，則僅能以 AUC 作為評估依據。

- 機器學習測試

Feature Filter :


☐ Importance > < View distribution

☐ AUC Value (%) > <

(1) Importance

- 在機器學習中，Importance (重要度) 代表某個特徵對模型預測結果的影響程度。Importance 越高，表示該特徵對模型判斷越重要，因此可以透過 Importance 篩選出較具代表性的特徵，例如找出對癌症與健康分類較重要的代謝體。

- 我們可以選擇一個 Threshold，作為評估各代謝體在資料中重要程度的依據。如果不知如何設定 threshold，我們有提供此資料集的 Importance 分布圖可以參考



(2) AUC

- AUC (Area Under Curve, 曲線下面積) 代表模型在區分兩個類別（例如癌症與健康）時的整體判斷能力，數值越高代表模型越能正確區分癌症與健康樣本。
- 在本網站，我們將 AUC 呈現範圍設定為 0.5 至 1，因為 0.5 代表模型判斷力等同於隨機猜測，是有意義分類的最低門檻，因此只呈現 0.5 以上的數值，方便使用者直接判讀該特徵的分類效果好壞。

4. 統計測試資料

“Fold Change of Average Strength” 與 “Statistical Significance” 皆屬在統計測試的資料。

(1) Fold change

- Fold Change (倍數變化) 代表某個代謝體在兩組樣本之間表現量的相對變化倍數，用來衡量該代謝體在不同組別間上升或下降的幅度。當 Fold Change 大於 1 時，表示該代謝體在癌症組的表現量高於健康組（上升）；小於 1 時則表示表現量較低（下降），因此可以透過 Fold Change 搭配統計顯著性，篩選出在癌症與健康之間差異較明顯的代謝體。
- 本網站所使用的 Fold Change 公式為：Condition 1/ Condition 2。

(2) 統計顯著性

- 統計顯著性 (Statistical Significance) 代表兩組樣本之間的差異是否為真實存在的差異，而非隨機誤差所造成，通常透過統計檢定計算出 p-value 或校正後的 q-value 來判斷；數值越小，代表該代謝體在兩組間的差異越不太可能是偶然發生，因此可以作為篩選具有生物意義代謝體的重要依據。
- 在本網站，使用者可以自行選擇檢定方法，包含 T test、KS test (Kolmogorov–Smirnov test) 以及 U test (Mann–Whitney U test)，以因應不同資料分佈特性的需求；同時也提供多重檢定校正方式，包含 FDR (False Discovery Rate)、Bonferroni 以及 None (不校正)，讓使用者可以自行調整。

Define differential expression :

Fold Change of Average Strength

☒ Condition 1 / Condition 2

≥

Statistical Significance

☒

Test:

Direction:

Correction:

q-value cutoff:

四、結果

在完成上述篩選條件（AUC、Importance、Fold Change、Statistical Significance）的設定後，系統會依照使用者選擇的各項門檻值與統計標準，自動篩選並整合出符合條件的代謝體清單，呈現於結果頁中。

結果頁會列出每個通過篩選的代謝體，以及其對應的各項指標數值（如 AUC、Importance、Fold Change、p-value/q-value 等），讓使用者能夠一目了然地比較不同代謝體在 Condition 1 與 Condition 2 之間的分類能力與差異程度，並可依此進一步排序、篩選出最具代表性的候選代謝體，作為後續實驗驗證或研究方向的參考依據。

Result

點擊表格標題可進行排序 | 支援搜尋功能 | 可匯出至 Excel


Excel ☐ 隱藏 Metabolite name = unknown 搜尋:

Metabolite	Metabolite name	Importance	AUC (%)	Condition 1 average	Condition 2 average	Fold change (Condition1/Condition2)	Q value
A_8.775_172.071	Unknown	1.932e-2	98.2%	71216289.35	2632299.72	27.05	3.08e-32
A_10.799_172.071	Unknown	1.658e-2	98.0%	50388915.44	2599892.52	19.38	1.84e-38
A_25.584_172.072	Unknown	7.432e-3	97.7%	14699217.59	1153661.46	12.74	8.91e-49
A_20.801_172.071	Unknown	2.770e-2	97.6%	15893821.23	1104365.94	14.39	1.69e-28
A_8.897_172.071	Unknown	3.149e-2	97.6%	67805880.33	2665922.03	25.43	4.09e-35

五、機器學習方法論

我們以大腸癌 vs 健康為例。

整體流程如下：




1. 資料前處理

由於資料型態為：連續 v.s. 連續，故使用 Pearson (R值) 去進行 correlation 計算。

- 計算所有 feature 兩兩之間的 R值後，以 connect component 去進行 clustering，此時資料會被分成 singleton(獨立、未與其他 feature 群聚的特徵) 及 cluster（由多個高度相關的 feature 組成的群集）。


- cluster : 從該 cluster 中挑選出 AUC 表現最佳 的代表性 feature，並篩選出 $AUC \geq 0.7$ 的 feature。
- **singleton** : 直接篩選 $AUC \geq 0.7$ 的 feature。
- 最後將上述篩選出的 feature 整合，並建立新的訓練集



2. 模型訓練


我們選擇的 Model 為 Random forest。

- 建立超參數 (Hyperparameter) 搜尋空間，並使用 random search 的方法進行上千次的組合嘗試，以找出表現較佳的超參數組合。
- 透過 5-fold 交叉驗證 (5-fold Cross Validation) 的方式，評估各組超參數在不同資料切分下的穩定性與預測效果，篩選出表現穩定且效果良好的超參數組合。
- 最終選擇表現最佳的超參數組合，作為建立最終模型的依據，並以此產出最後的預測結果。



六、附錄

1. Permutation test



2. PCA

