

Conclusion

本次競賽中最終取得 Private Leaderboard 第 4 名、Public Leaderboard 第 7 名的成績。
本專案比較了 DeepLabV3 (ResNet-50 骨幹) 與 SegFormer (MiT-B4 架構) 兩種語意分割模型，並選擇 SegFormer 作為最終主力模型，在 UAV 語意分割訓練資料上取得約 0.76 的 mIoU 與約 0.92 的準確率，整體表現穩定。雖然在稀有類別與小物件邊界的辨識上仍有進步空間，但此次成果已驗證了 Transformer-based 模型在該任務上相較於傳統 CNN 架構的競爭力。

Public Leaderboard

Public Private							
This leaderboard is calculated with approximately 80% of the test data. The final results will be based on the other 20%, so the final standings may be different.							
#	Team	Members	Score	Entries	Last	Solution	
1	NN6141016		0.697245	39	10mo		
2	N26144395		0.681385	69	10mo		
3	E14116613		0.667444	4	10mo		
4	NM6144046		0.667132	15	10mo		
5	N26140870		0.663040	21	10mo		
6	林冠廷 LIN KUAN TING Q36141032		0.660073	10	10mo		
7	N26141216		0.649363	26	10mo		

Private Leaderboard

Public Private							
The private leaderboard is calculated with approximately 20% of the test data. This competition has completed. This leaderboard reflects the final standings.							
#	△	Team	Members	Score	Entries	Last	Solution
1	▲ 11	R76144144		0.591632	22	10mo	
2	▲ 6	R36144146		0.588858	90	10mo	
3	▲ 10	R76144102		0.583925	66	10mo	
4	▲ 3	N26141216		0.583468	26	10mo	

Data Analysis & Preprocessing

Dataset Exploration

本次競賽使用的 UAV 語意分割資料集，共包含 4,000 張影像。

為提升模型的泛化能力與穩定性，採用 5 折交叉驗證（5-Fold Cross Validation）進行訓練與驗證資料的切分。

資料集平均劃分為五個子集，每一折中：

- 訓練集（Training set）使用其中四個子集，共 3,200 張影像（佔 80%）。
- 驗證集（Validation set）使用剩下一個子集，共 800 張影像（佔 20%）。


在五次交叉驗證過程中，每張影像皆會被用作一次驗證資料，確保模型能在不同資料分布下進行評估，減少過擬合風險。

此外，每張影像皆附有對應的語意分割標註，共區分為 16 類別。

類別分布呈現不均衡現象，主要像素集中於：

- 類別 0（32.98%）、類別 1（23.88%）、類別 2（13.21%）、類別 3（8.78%）；
- 而少數類別（12–15）僅佔總像素數的 1% 以下。

class distribution



example images




Image Preprocessing & Augmentation

在模型訓練前，所有輸入影像皆進行統一的前處理(Image Preprocessing)與增強流程(Augmentation)。

Image Preprocessing

在輸入模型前，所有影像皆先進行統一前處理。

首先以 OpenCV 讀取影像並轉換為 RGB 格式，再將像素值正規化至 $[0, 1]$ 範圍。接著根據 ImageNet 統計值進行標準化（平均值 $[0.485, 0.456, 0.406]$ ；標準差 $[0.229, 0.224, 0.225]$ ），以確保影像分布與 SegFormer 預訓練模型一致。最後將影像轉換為 PyTorch Tensor，通道順序調整為 (C, H, W)。

Data augmentation

為提升模型對於光照、視角與解析度變化的泛化能力，訓練階段採用了多種資料增強策略，包括：

- 隨機水平翻轉 ($p=0.5$)：反轉影像與對應的遮罩，提升方向不變性。
- 隨機縮放與中心裁剪 ($0.75 - 1.25$)：模擬不同拍攝距離與構圖。
- 色彩抖動：隨機調整亮度、對比與飽和度，模擬多種環境光源。
- 高斯模糊 ($p=0.2$)：隨機套用 3×3 或 5×5 核，提升對模糊影像的魯棒性。

這些增強方法能有效提升模型的泛化能力。在驗證與測試階段，則僅進行標準化處理，不使用任何隨機變換，以確保模型評估的一致性與可重現性。

Model Selection & Training

Model Architecture

本研究採用 SegFormer 作為語意分割模型。SegFormer 基於 Transformer 架構所提出的模型，結合了 層次化 Transformer 編碼器（MiT，Mix Transformer）與輕量化解碼器（MLP Decoder），在保持高準確度的同時，運算效率優於傳統 CNN 模型（如 DeepLabV3+、U-Net）。此特性特別適合用於無人機（UAV）高空影像的地物分類任務，因其能同時捕捉全域語意與局部細節。

SegFormer 的主幹網路為 MiT-B4，共包含四個階段：

- Stage 1：3 層，64 個通道
- Stage 2：8 層，128 個通道
- Stage 3：27 層，320 個通道
- Stage 4：3 層，512 個通道

每層皆包含 自注意力機制（Self-Attention）與 Layer Normalization，啟用函數為 GELU。解碼器部分利用多層感知機（MLP）融合不同尺度的特徵圖，最後經雙線性插值（Bilinear Interpolation）還原至原圖大小，以產生每個像素的 16 類別預測。

在訓練設定上，使用 AdamW 優化器，並搭配 OneCycleLR 動態調整學習率。損失函數為 Cross Entropy Loss 與 IoU Loss 的加權組合，並採用 混合精度訓練（FP16）以提升效率。整體而言，SegFormer 在本任務中能兼顧準確率、速度與泛化能力，特別適合 UAV 遙測場景的語意分割。

Loss Function & Optimization

Loss Function

採用 CrossEntropy Loss 與 IoU Loss 的加權組合作為整體損失函數。

1. CrossEntropy Loss

由於語意分割屬於多類別分類問題，交叉熵損失能有效衡量模型預測的機率分佈與真實標籤之間的差異。在訓練中額外使用 `label_smoothing=0.05`，可降低模型對單一類別過度自信的情況，增進泛化能力。同時設定 `ignore_index=255` 以忽略標註中不需參與訓練的區域。

2. IoU Loss

為了讓模型在像素層級上更注重邊界與形狀的準確性，額外引入 IoU（Intersection over Union）損失。IoU Loss 以類別的交集與聯集比例為基礎計算，可直接反映語意分割的核心評估指標（mIoU）。

在最終損失中採用加權組合：

$$\text{Total Loss} = \text{CE Loss} + \alpha \times \text{IoU Loss}$$

其中 α 為 IoU 權重，此次設定為 2，使模型在學習過程中更關注物件區域的重疊比例。

Optimization

1. Optimizer

模型使用 AdamW 作為最佳化演算法。

與傳統 Adam 不同，AdamW 將權重衰減（weight decay）從動量更新中分離，能有效防止過度擬合，同時保有 Adam 的自適應學習率特性。

- 初始學習率：2e-5
- 權重衰減：0.01

2. Learning Rate Scheduler

採用 OneCycleLR 學習率排程策略。

此方法在訓練初期先逐步提升學習率至峰值（max_lr=2e-4），之後再逐步降低，使模型能在前期快速收斂、後期穩定微調，有助於獲得更佳的最終泛化表現。

3. Mixed Precision Training

訓練過程中搭配 torch.cuda.amp 自動混合精度訓練（autocast 與 GradScaler），在不影響數值穩定性的前提下，能顯著提升 GPU 計算速度並減少記憶體使用量。

Training Process & Hyperparameters

本模型的訓練採用 K-Fold Cross Validation（K=5），每個 fold 使用 80% 資料作為訓練集、20% 作為驗證集，以確保模型泛化能力。每次訓練共進行 55 個 epochs，batch size = 6，並以 CUDA GPU 執行。

為提升穩定性與避免過擬合，本專案採用多項策略：

1. 資料增強（Data Augmentation）：包含隨機水平翻轉、隨機縮放裁切、亮度/飽和度變化與高斯模糊，以增加影像多樣性。

2. 權重正則化：AdamW 優化器內建 $\text{weight decay} = 0.01$ ，可抑制權重過大。
3. 動態學習率調整：使用 OneCycleLR 使學習率在訓練過程中先升後降，減少陷入區域極值的風險。
4. Batch Normalization / Layer Normalization：SegFormer 內部採 LayerNorm 穩定訓練分佈。
5. 混合精度訓練 (FP16)：利用 autocast 與 GradScaler 降低運算成本並提升訓練速度。

整體流程可有效減少 overfitting 現象並提升模型在測試集上的泛化表現。

Experiment & Results

Comparison of Different Approaches

在本次競賽中，我分別使用了兩種語意分割模型：DeepLabV3（以 ResNet-50 為骨幹網路）與 SegFormer（MiT-B4 架構），並針對其效能與特性進行比較分析。

(1) DeepLabV3 + ResNet50：

此模型採用傳統的卷積神經網路（CNN）架構，透過 Atrous Convolution 與 ASPP 模組（Atrous Spatial Pyramid Pooling）擴大感受野，以提升對大型物體的辨識能力。

優點：

- 架構穩定、訓練容易收斂。
- 空洞卷積與 ASPP 模組能有效擴大感受野，對大型物體分割效果良好。
- 有豐富的預訓練權重資源可供微調，遷移性高。

缺點：

- GPU 記憶體消耗較高，需使用較小的 batch size，進而降低整體訓練效率。
- 模型對小物體與邊界區域的辨識較弱。
- 泛化能力較差，對不同場景或亮度變化的資料敏感，易過擬合。

(2) SegFormer（MiT-B4）：

SegFormer 採用 Transformer 編碼器（Mix Transformer）結合 MLP 解碼器，能同時捕捉全域語意與局部細節特徵。解碼端結構簡潔、計算量小，可高效融合多層特徵圖。實驗結果顯示，SegFormer 的驗證集 mIoU 約提升 4%（0.60 → 0.64），在邊界物件與小面積類別的分割上表現更穩定。

優點：

- 具備長距離注意力機制，可捕捉全域語意，分割邊界更精確。
- MLP 解碼器設計輕量，運算效率高、記憶體需求低。
- 泛化能力佳，能適應不同環境與影像條件。

缺點：

- 訓練時間較長。
- 需要較大的、多樣的訓練資料集，若資料不足則需藉由 Data Augmentation 來補足多樣性，否則 Transformer 架構容易過擬合。

整體而言，SegFormer 在準確率、泛化能力與記憶體效率方面皆優於 DeepLabV3。雖然模型規模較大、訓練時間較長，但在 UAV 影像場景中能更有效整合全域與局部資訊，因此被選為本次競賽的最終模型。

Error Analysis & Model Improvements

Error Analysis

在完成模型比較與超參數調整後，SegFormer 模型於驗證集的表現進一步提升。根據訓練紀錄，模型最終在驗證集達到 $mIoU \approx 0.76$ 、 $val_acc \approx 0.92$ ，較初期比較實驗階段的 $mIoU$ 0.64 有明顯提升，整體收斂穩定且表現良好。然而，從各類別 IoU 分布可以看出顯著的長尾與不平衡現象：

1. 主要物件表現優異 (Class 0–4, 6, 13)

- 這些類別 IoU 介於 0.8 – 0.95，代表模型能正確辨識常見且面積較大的區域。
- 這些物件特徵明顯、樣本量大，學習效果穩定。

2. 中小型物體仍有誤判 (Class 5, 7–12, 14, 15)

- IoU 普遍偏低 (部分低於 0.5，甚至接近 0)，特別是 Class 7–15 初期幾乎無法辨識。
- 代表模型對小面積或稀有類別的辨識能力不足。
- 這些錯誤主要出現在：
 - 邊界模糊：小物件邊緣被鄰近類別吞併。
 - 背景誤判：面積過小導致預測偏向背景類。
 - 樣本不足：類別在資料集中出現次數極低，導致學習不穩。

3. 跨折表現一致但初期波動大

- 各 fold 前 5–10 epoch $mIoU$ 成長迅速 (0.1 $\rightarrow$ 0.6)，顯示預訓練權重有效；
- 但低頻類別 (如 Class 14–15) 即使在後期仍低於 0.55，顯示模型在長尾學習上尚有瓶頸。

Model Improvements

1. 資料層面：強化稀有類別學習

- Class-balanced weighting：依據像素比例設定損失權重，讓稀有類別 (Class 7–15) 在訓練中獲得更高梯度。
- Oversampling / Patch cropping：增加小物體所在區域的取樣頻率，確保每批訓練資料

都有多樣物件分佈。

- 進階資料增強：加入隨機旋轉、CutMix、光照變化模擬、或 Random Erasing，提高模型對環境變化的穩健性。

2. 模型層面：結構與訓練策略調整

- 提高解析度訓練：以更高輸入解析度（如 768×768）強化小物件特徵。
- 後處理優化：導入 CRF (Conditional Random Field) 或 SegFix，改善邊緣模糊與類別過渡錯誤。
- TTA / Ensemble：於推論階段進行多尺度、翻轉增強或多模型加權平均，提升泛化性。

3. 超參數微調

- 學習率排程：目前使用 OneCycleLR，可考慮在後期改為 CosineAnnealingLR，讓模型持續微調稀有類別。
- IoU Loss 權重調整：可將 IoU 權重由 2.0 提升至 2.25、2.5，使模型更關注小物件邊界。
- 延長訓練週期：目前 55 epoch 已收斂，可延長至 80 epoch 並降低最終學習率，加強微調效果。